

Оглавление

Постановка задачи	3
План практики.....	3
Часть I: Ознакомление с основами топологического анализа данных и изучение базовых статей	4
1) Подготовительный этап:	4
2) Обзор статей:	4
3) Математическая модель:.....	5
Часть II: Реализация программы для применения изучаемых методов	5
1) MIDI и их обработка:	5
2) Построение фильтрации Чеха:	6
3) Вычисление баркодов и их статистик:	6
Часть III: Проведение анализа полученных результатов.....	7
1) Установки и параметры:	7
2) Баркоды:.....	7
3) Один жанр, разные авторы:	9
4) Один автор, разные жанры:	11
5) Итог:	12
Результаты практики	13
Список литературы	14

Постановка задачи

Главной задачей данной практики являлось применение методов топологического анализа данных в условиях несимметричной функции расстояния между объектами, а более конкретно – функции, принадлежащей классу дивергенций Брэгмана. Объектом исследования являлись академические музыкальные произведения – струнные квартеты Йозефа Гайдна, Людвиг ван Бетховена и Вольфганга Амадея Моцарта. Полученные результаты предполагалось сравнить с результатами работы «*Musical Stylistic Analysis: A Study of Intervallic Transition Graphs via Persistent Homology*» (1), применяющей иной подход – первоначальную симметризацию функции расстояния с последующим построением вспомогательного метрического пространства, анализ топологических характеристик которого и проводился в дальнейшем. Для успешного достижения поставленной задачи она была разбита на подзадачи, для которых был составлен план.

План практики

Планируемые задачи и результаты:	1. Ознакомление с основами топологического анализа данных и изучение базовых статей
	2. Реализация программы для применения изучаемых методов
	3. Проведение анализа полученных результатов
	4. Написание отчета по результатам практики

Часть I: Ознакомление с основами топологического анализа данных и изучение базовых статей

1) Подготовительный этап:

Для изучения базовых статей (1), (2), на которые впоследствии опиралась данная работа, необходимо было предварительно ознакомиться с основными концептами и понятиями топологического анализа данных. После ознакомления с материалами соответствующего курса для ФКН и ШАД (3) и вспомогательной статьей, обобщающей основные подходы к топологическому анализу данных как с теоретической, так и с практической стороны (4), были изучены все необходимые для последующей работы понятия, такие как: симплекс, симплициальный комплекс и его фильтрация, нерв покрытия и теорема о нем, комплексы и фильтрации Чеха и Виеториса–Рипса, группа гомологий, устойчивые гомологии, «баркоды»

2) Обзор статей:

Работа «*Musical Stylistic Analysis: A Study of Intervallic Transition Graphs via Persistent Homology*» (1) предлагает использовать в музыковедческом анализе распределение различных статистик устойчивых гомологий, построенных на основе матриц частот переходов между тонами в партиях различных произведений. Сравнение характеристик данных распределений, таких, например, как стандартное отклонение, позволяет делать выводы как о творческих диапазонах разных авторов, так же и о единообразии или, наоборот, разнородности произведений одного автора в рамках разных жанров. Авторы данной статьи работали со струнными квартетами, извлекая из партии каждого из четырех инструментов матрицу размера 12 на 12, каждый элемент которой соответствовал частоте переходов от соответствующего тона к соответствующему, подсчитанной с учетом длины нот (чем дольше они звучат, тем с большим весом учитывается переход между ними). Затем по данной матрице как по матрице смежности строился взвешенный ориентированный граф, который впоследствии трансформировался во взвешенный неориентированный граф (посредством добавления вспомогательных вершин, соответствующих ребрам и соединения их с соответствующими оригинальными вершинами), на основе которого уже строилось метрическое пространство. По нему затем строилась фильтрация Виеториса–Рипса, чьи статистики (среднее, дисперсия и энтропия долей длин жизни устойчивых гомологий первой и нулевой групп) впоследствии и замерялись.

Как замечают, однако, сами авторы в конце работы, подход, опирающийся на использование метрического пространства, обладает некоторыми недостатками: дополнительно требует индуцирования неориентированного графа, а самое главное – не учитывает возможную асимметрию расстояния между объектами. Довольно широким классом асимметричных мер расстояний между двумя объектами являются дивергенции Брэгмана. Работа «*Topological Data Analysis with Bregman Divergences*» (2) предлагает алгоритмическую реализацию построения фильтраций на основе мер расстояния данного класса, а также теоретическое обоснование корректности и оптимальности алгоритмов построения такой конструкции. На применении этих подходов в сеттинге первой статьи (1) и была сосредоточена работа в рамках данной практики.

3) Математическая модель:

Метод исследования и сравнения характеристик различных групп музыкальных произведений, используемый в ходе данной практики, во многом совпадает с таковым из оригинальной статьи (2). По такому же принципу извлекались матрицы частот переходов между тонами в самом начале пайплайна, и по такому же принципу сравнивались и анализировались распределения статистик фильтраций в самом конце. Отличался лишь метод построения фильтраций на основе матриц частот переходов. Вместо построения метрического пространства из некоторого взвешенного неориентированного графа, индуцированного матрицей, фильтрация строилась непосредственно на 12 точках 12-мерного пространства, задаваемых строками (столбцами) самой матрицы. Каждая строка содержит в себе неотрицательные действительные числа и соответствует распределению переходов от конкретного тона к остальным тонам (возможно нормированного некоторой константой). Одной из популярных мер схожести распределений является дивергенция Кульбака–Лейблера, которая и была использована для построения фильтраций. Итого для каждой матрицы размера 12 на 12 была построена фильтрация на основе комплексов Чеха, построенных на 12 вершинах в 12-мерном пространстве, соответствующих строкам матрицы. Выбор в пользу фильтрации Чеха вместо Виеториса–Рипса здесь обосновывается тем, что последняя может значительно отличаться от фильтрации объединения шаров с растущим радиусом, совпадающей по теореме о нерве с фильтрацией Чеха. Данный эффект является особенностью сеттинга с асимметричными расстояниями – в обычных метрических пространствах фильтрации Виеториса–Рипса чаще всего довольно неплохо аппроксимируют фильтрации Чеха, а также обладают значительно меньшей вычислительной стоимостью, вследствие чего и используются. Нам, однако, переживать за вычислительную стоимость построения фильтрации Чеха не стоит, так как она будет строиться при помощи сконструированных авторами одной из статей (2) оптимизированных алгоритмов, корректность которых обусловлена принадлежностью радиус-функции Чеха к классу обобщенных дискретных функций Морса.

Подытоживая, общий пайплайн имеет следующий вид: каждая из четырех партий произведения преобразовывается в матрицу частот переходов между тонами; на основе строк этой матрицы как точек в пространстве и KL-дивергенции как функции расстояния между ними строится фильтрация Чеха; из данной фильтрации извлекаются характеристики устойчивых гомологий – так называемые баркоды; по данным баркодам подсчитываются различные статистики – среднее, дисперсия, энтропия долей их длин; сравниваются и анализируются распределения данных статистик в разных группах.

Часть II: Реализация программы для применения изучаемых методов

1) MIDI и их обработка:

Авторы оригинальной статьи (1) работали с файлами формата MIDI, который позволяет содержать в цифровой форме последовательность и совокупность звуков, соответствующих нажатиям на клавиши синтезатора, а также их акустических характеристик – тембра, темпа, тона, длительности и т.д. Для работы с файлами такого формата авторы использовали специальный пакет функций MIDI Toolbox (5) для языка программирования MATLAB. Данный пакет предоставляет доступ к функции, вычисляющей нужную матрицу частот переходов.

Так как одной из целей практики было сравнение двух подходов к построению фильтраций (на основе метрических пространств и на основе дивергенций Брэгмана), репликация процесса предварительного извлечения данных для построения фильтраций не могла не поспособствовать чистоте эксперимента. А потому в данной работе для получения матрицы частот переходов использовалась та же самая библиотека, а точнее даже был использован код самих авторов оригинальной статьи. Чтобы использовать MATLAB функции вместе с основным кодом, написанным на Python, был использован MATLAB Engine API.

Что касается самих MIDI файлов, данные для данной работы были взяты с сайта <https://www.stringquartets.org/> (6), так как он позволял бесплатно скачивать (причем сразу все) доступные MIDI файлы, в то время как многие другие онлайн ресурсы имели ограничение на количество скачиваемых без платной подписки файлов в день. Итого было скачано 17 струнных квартетов Бетховена, 44 Гайдна и 10 Моцарта. Каждый из них содержит (чаще всего) 4 части, около 10 файлов были повреждены, что по итогу складывается в весомую выборку из ~275 произведений, хоть и отличную от набора из оригинальной статьи «*Musical Stylistic Analysis: A Study of Intervallic Transition Graphs via Persistent Homology*» (1). Сайт также обозначает жанровую принадлежность каждого из произведений, что позволило автоматически сопоставить каждому скачанному файлу произведения его жанр путем несложного парсинга веб-страницы.

2) Построение фильтрации Чеха:

Радиус-функция Чеха вычислялась в полном соответствии с алгоритмом, предложенным в вышеупомянутой статье «*Topological Data Analysis with Bregman Divergences*» (2). Данный алгоритм требует нахождения описанного шара Брэгмана симплекса, т.е. нахождения такой точки и радиуса, что расстояние Брэгмана (в нашем случае это KL-дивергенция) от этой точки до всех точек симплекса равно данному радиусу. Как показано в статье, задача поиска такой точки и радиуса является выпуклой задачей оптимизации, причем ее размерность совпадает с размером симплекса, а так как при построении фильтрации нас чаще всего интересуют лишь симплексы малого размера (от 1 до 3 вершин), это позволяет оптимально использовать методы оптимизации второго порядка. В данной работе использовался квази-Ньютоновский метод второго порядка BFGS в соответствии с рекомендацией авторов статьи, а более конкретно – его реализация в пакете SciPy (7).

3) Вычисление баркодов и их статистик:

После подсчета значений радиус-функции Чеха для нужных симплексов следовало вычисление баркодов соответствующих фильтраций. Для решения данной задачи был использован функционал библиотеки GUDHI (8), выбор в пользу которой был совершен по причине простоты в установке, наличия необходимого функционала (подсчет баркодов по уже готовым фильтрациям), вычислительной эффективности, отмеченной в статье «*A Roadmap for the Computation of Persistent Homology*» (4), а также рекомендаций от семинаристов курса по топологическому анализу данных.

После вычисления баркодов по ним подсчитывались определенные статистики – среднее и стандартное отклонение их длин, а также энтропия распределения, заданного долями длин баркодов от их общей суммы длин. Для каждого из четырех инструментов

подсчитывалось по 3 статистики для каждой из первых 2 или 3 групп гомологий – итого получались 24-мерные или 36-мерные вектора.

Часть III: Проведение анализа полученных результатов


1) Установки и параметры:

Как уже было оговорено ранее, весь пайплайн обладает некоторыми гиперпараметрами запуска, основные из которых – количество групп исследуемых гомологий (2 или 3), выбор вершин комплексов (строки или столбцы) и выбор их значений (нормализованные к сумме значений 1 или не нормализованные). Однако после запуска всех 8 комбинаций этих параметров значительные различия между их результатами не наблюдались. Потому, в то время как результаты, приведенные далее, были получены при эксперименте со стандартными значениями гиперпараметров (2 группы гомологий на нормализованных строках), они все же обладают некоторой универсальностью относительно выбора этих самых параметров.


2) Баркоды:

Перед тем как сравнивать распределения статистик в разных группах произведений, для начала сравним полученные баркоды для двух разных методов – подхода с дивергенциями Брэгмана и подхода из статьи (1) с фильтрацией Виеториса–Рипса. На примере построенных баркодов устойчивости гомологий для первой скрипки первой части работы 20/1 Йозефа Гайдна можно наглядно видеть отличия в структуре двух фильтраций комплексов.

Persistence barcode




Persistence barcode




Баркоды устойчивости гомологий фильтрации, построенной согласно статье (1)

Persistence barcode



Persistence barcode



Баркоды устойчивости гомологий фильтрации Чеха, построенной с дивергенциями Брэгмана


Для фильтрации Виеториса–Рипса, построенной на индуцированном неориентированном взвешенном графе, мы можем видеть гораздо большее количество гомологий нулевой группы (компонент связности), что логично, ведь в ходе получения взвешенного неориентированного графа в качестве вершин были добавлены все существующие ребра, то есть всего вершин в итоговом комплексе порядка квадрата от исходного количества – двенадцати. В случае с фильтрацией Чеха, построенной на основе дивергенций Брэгмана, дополнительные вершины не добавляются, поэтому компонент связности максимум 12.

Однако несмотря на такое значительное различие в порядках количества вершин, количество устойчивых гомологий первой группы разнится в совершенно другом направлении – для фильтрации Чеха наблюдается примерно в два раза большее количество различных устойчивых гомологий первого порядка, чем для фильтрации Виеториса–Рипса из оригинальной статьи (1). Объяснить это можно, во-первых, значительным отличием асимметричных дивергенций Брэгмана в случае фильтрации Чеха от расстояний из фильтрации Виеториса–Рипса, подчиняющихся аксиомам метрических пространств. Во-вторых, фильтрация Виеториса–Рипса включает симплекс в комплекс при попарном пересечении шаров текущего радиуса с центрами в вершинах, а фильтрация Чеха – при общем пересечении. В случае с одномерными цепями разницы нет, а вот одномерные границы будут появляться в фильтрациях Виеториса–Рипса раньше, чем в фильтрациях Чеха, а значит и одномерные гомологии будут реже появляться и раньше умирать. В статье, посвященной дивергенциям Брэгмана, (2) показано, что отличие в радиусах, необходимых для появления симплекса в комплексах Виеториса–Рипса и Чеха, может быть сколь угодно большим в случае работы с дивергенцией Кульбака–Лейблера.

Подобное различие в топологических характеристиках фильтраций позволяет сделать вывод о том, что применение дивергенций Брэгмана дает возможность взглянуть на те же самые объекты с совершенно другой перспективы. Далее перейдем непосредственно к сравнительному анализу различных групп произведений.


3) Один жанр, разные авторы:

Сравнение произведений трех авторов в рамках конкретных жанров давало различные результаты в зависимости от выбранных жанров. Стоит заметить, однако, что в случае со многими жанрами имеет место некоторая несбалансированность между авторами. К примеру, в жанре *Adagio* произведений Моцарта в выборке меньше пяти штук, в то время как произведений Гайдна порядка двадцати. Двумя жанрами с относительно сбалансированным между авторами количеством произведений, пожалуй, являлись *Andante* и *Allegro*. Для первого удалось пронаблюдать порядок стандартных отклонений у авторов схожих с полученным в оригинальной статье «*Musical Stylistic Analysis: A Study of Intervallic Transition Graphs via Persistent Homology*» (1), а именно – низкую дисперсию распределения статистик в произведениях Гайдна, более высокую в произведениях Моцарта и высочайшую в произведениях Бетховена. Схожим образом так же и распределены точки на двумерной плоскости, полученные из статистик методом главных компонент.




Распределения точек и их стандартное отклонение (жанр *Andante*)

Что касается жанра *Allegro* – в этом жанре произведения Гайдна наоборот обладали наибольшим разбросом.




Распределения точек и их стандартное отклонение (жанр *Allegro*)

Взяв же в рассмотрение все доступные произведения авторов, мы опять получим картину, схожую с полученной авторами оригинальной статьи.



Распределения точек и их стандартное отклонение (все жанры)


Приведем для сравнения результаты из работы «*Musical Stylistic Analysis: A Study of Intervallic Transition Graphs via Persistent Homology*» (1).



Распределения точек и их стандартное отклонение (1)


4) Один автор, разные жанры:

Кроме сравнения распределений статистик в группах, объединенных по автору, мы можем также рассмотреть и группы произведений одного автора в рамках разных жанров. Так как Гайдн обладает наиболее широкой коллекцией произведений, сравнивать мы будем именно его работы. А именно были сопоставлены работы семи его жанров, наиболее представленных в базе данных: *Allegro*, *Allegretto*, *Presto*, *Adagio*, *Andante*, *Vivace*, *Menuetto*. После PCA преобразования получились следующие результаты:



Распределения точек и их стандартное отклонение (один автор, разные жанры)

Для сравнения стоит привести также и соответствующие показатели, полученные авторами оригинальной работы:



Распределения точек и их стандартное отклонение (1)

При сравнении полученных результатов можно заметить несколько отличий. В то время как жанр *Menuetto* в обоих случаях обладает одной из наименьших дисперсий, жанры *Allegro*, *Presto* и *Adagio* в рамках разброса упорядочены в противоположном порядке. Такое несовпадение, пожалуй, все же может быть объяснено различиями в выборке произведений.

5) Итог:

Подытоживая анализ полученных результатов, можно заключить, что используемая в данной работе математическая модель способна как реплицировать результаты предложенных ранее методов топологического анализа данных, так и предоставлять новый взгляд на анализ данных за счет возможности использования асимметричных мер расстояния между объектами.

Результаты практики

В ходе практики были выполнены и достигнуты следующие шаги и результаты

- 1) Были изучены теоретические и прикладные основы топологического анализа данных.
- 2) Были изучены работы «*Musical Stylistic Analysis: A Study of Intervallic Transition Graphs via Persistent Homology*» (1) и «*Topological Data Analysis with Bregman Divergences*» (2).
- 3) На основе результатов данных статей была построена математическая модель для исследования музыкальных произведений.
- 4) На основе результатов данных статей был написан код, реализующий данную математическую модель. Весь код загружен в репозиторий <https://github.com/FedorZaitsev/Bregman-TDA-practice>
- 5) Был проведен анализ полученных при помощи модели результатов.

Список литературы

1. *Musical Stylistic Analysis: A Study of Intervallic Transition Graphs via Persistent Homology*. **Martín Mijangos, Alessandro Bravetti, Pablo Padilla**. б.м. : Taylor & Francis, 26 Апрель 2024 г., Journal of Mathematics and Music, Т. 18, стр. 89-108.
2. *Topological Data Analysis with Bregman Divergences*. **Herbert Edelsbrunner, Hubert Wagner**. б.м. : arXiv, 21 Июль 2016 г.
3. **HSE, ATA LAB**. TDA for FCS and YDS. [В Интернете] Весна 2024 г. [Цитировано: 15 Июль 2024 г.] – Режим доступа: свободный.
<https://www.youtube.com/playlist?list=PL0thilv9RYSLmZyHYCRR2IG0dYJXhagDN>.
4. *A roadmap for the computation of persistent homology*. **Nina Otter, Mason A. Porter, Ulrike Tillmann, Peter Grindrod, Heather A. Harrington**. 9 Август 2017 г., EPJ Data Science, Т. 6.
5. **Toivaiainen, P., Eerola, T**. MIDI toolbox 1.1. [В Интернете] 18 Апрель 2016 г. [Цитировано: 15 Июль 2024 г.] – Режим доступа: свободный. <https://github.com/miditoolbox/1.1>.
6. STRING QUARTETS. [В Интернете] [Цитировано: 15 Июль 2024 г.] – Режим доступа: свободный.
<https://www.stringquartets.org/>.
7. *SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python*. **Pauli Virtanen, Ralf Gommers, Travis E. Oliphant**. б.м. : Nature Methods, 2020 г., Т. 17, стр. 261-272. – Режим доступа: свободный.
8. **The GUDHI Project**. GUDHI User and Reference Manual. *GUDHI*. [В Интернете] 2024 г. [Цитировано: 15 Июль 2024 г.] – Режим доступа: свободный. <https://gudhi.inria.fr/doc/3.10.1/>.